

RECONHECIMENTO ÓPTICO DE CARACTERES UTILIZANDO NEURÔNIOS ADALINE: UMA ANÁLISE EXPERIMENTAL DE GENERALIZAÇÃO E ROBUSTEZ COM FONTES DESCONHECIDAS

Bruno Gomes Cordeiro¹
Kênya Magalhães dos Santos²
Fábio Henrique M. Oliveira³

RESUMO

Este artigo apresenta a reprodução metodológica e a modernização de um classificador conexionista clássico baseado na arquitetura Adaline (*Adaptive Linear Neuron*) para o reconhecimento óptico de caracteres (OCR). O ecossistema foi totalmente desenvolvido em ambiente Python, implementando rotinas de Processamento Digital de Imagens (PDI) com a biblioteca OpenCV para a extração de matrizes binárias padronizadas de 20X20 pixels. Adotou-se a estratégia de classificação multidimensional *One-vs-All* (Um contra Todos) com 26 neurônios paralelos para decodificar o alfabeto latino de A a Z. O diferencial desta abordagem consistiu em treinar a rede estritamente com duas fontes tipográficas (Arial e Times New Roman) e submeter o modelo a testes morfológicos com três fontes desconhecidas (Calibri, Verdana e Courier). Os ensaios revelaram alta vulnerabilidade e perda de acurácia frente a fontes de espaçamento fixo com serifas acentuadas (Courier). O fenômeno valida empiricamente as restrições e as limitações geométricas de fronteiras de decisão estritamente lineares na análise pixel a pixel.

Palavras-chave: Adaline, Regra Delta, Processamento Digital de Imagens, Generalização de Fontes, Visão Computacional.

RESUMO EM LÍNGUA ESTRANGEIRA

This article presents the methodological reproduction and modernization of a classic neural network classifier based on the Adaline (*Adaptive Linear Neuron*) architecture for optical character recognition (OCR). The ecosystem was developed entirely in a Python environment, implementing Digital Image Processing (DIP) routines using the OpenCV library to extract standardized 20×20-pixel binary matrices. The One-vs-All multidimensional classification strategy was adopted, using

¹ Graduando em Tecnologia em Sistemas para Internet no Instituto Federal de Ciência, Tecnologia e Educação de Brasília - Campus Brasília. E-mail: bruno63072@estudante.ifb.edu.br

² Graduanda em Tecnologia em Sistemas para Internet no Instituto Federal de Ciência, Tecnologia e Educação de Brasília - Campus Brasília. E-mail: kenny51498@estudante.ifb.edu.br

³ Bacharel em Sistemas de Informação, Doutor em Engenharia Elétrica com ênfase em Engenharia Biomédica e Professor do Instituto Federal de Ciência, Tecnologia e Educação de Brasília – Campus Brasília. E-mail: fabio.oliveira@ifb.edu.br

26 parallel neurons to decode the Latin alphabet from A to Z. The unique feature of this approach was training the network strictly with two typefaces (Arial and Times New Roman) and subjecting the model to morphological tests with three unknown typefaces (Calibri, Verdana, and Courier). The tests revealed high vulnerability and a loss of accuracy when faced with fixed-spacing fonts with pronounced serifs (Courier). This phenomenon empirically validates the geometric constraints and limitations of strictly linear decision boundaries in pixel-by-pixel analysis.

Keywords: Adaline, Delta Rule, Digital Image Processing, Font Generalization, Computer Vision.

1. INTRODUÇÃO

O desenvolvimento de sistemas artificiais baseados em Redes Neurais Artificiais (RNAs) para identificação de padrões apoia-se na capacidade de extrair características automaticamente a partir de um conjunto de exemplos (BRAGA; CARVALHO; LUDERMIR, 2000). Entre as topologias fundamentais da teoria conexionista, o modelo Adaline (*Adaptive Linear Neuron*), formulado por Widrow e Hoff (WIDROW; HOFF, 1960), destaca-se por estabelecer uma função de custo contínua baseada no erro quadrático médio das pré-ativações. Esse princípio matemático dita que o conhecimento representado no modelo serve para ponderar a entrada recebida por cada neurônio.

Este trabalho documenta e analisa a implementação prática de uma arquitetura Adaline para o reconhecimento das 26 letras do alfabeto latino. A pesquisa toma como diretriz metodológica o estudo clássico de (OLIVEIRA; BRAGA, 2012), estendendo a discussão original para um cenário moderno de testes em ambiente Python focado em hiperparâmetros adaptativos. O escopo central desta análise reside em avaliar com rigor científico a capacidade de generalização e a sensibilidade morfológica do algoritmo face a padrões tipográficos inéditos, determinando os limites onde os classificadores lineares pixel a pixel falham.

2. FUNDAMENTAÇÃO TEÓRICA

O aspecto central que diferencia a unidade Adaline do Perceptron clássico localiza-se no ponto de origem do cálculo do erro. Enquanto o algoritmo do Perceptron realiza ajustes nos pesos apenas quando a saída obtida após a ativação discreta diverge do valor desejado, o Adaline adapta seus coeficientes em função direta da sua saída linear, computada antes do limiar de ativação (FAUSETT, 1994).

Considerando um vetor de estímulos de entrada $X = [x_1, x_2, \dots, x_n]^T$, o potencial de ativação linear (y) é definido pela soma ponderada dos pesos sinápticos (ω) acrescida de um termo de bias (β):

$$y = \sum_{i=1}^n w_i x_i + b$$

A discretização e classificação bipolar do caractere ocorre em estágio posterior por meio de uma função degrau de transferência para saídas bipolares:

$$\hat{y} = +1 \text{ se } y \geq 0$$

$$\hat{y} = -1 \text{ se } y < 0$$

O algoritmo de treinamento tenta minimizar a função correspondente à soma dos erros quadráticos descrita pela Equação 1, onde y representa a resposta alvo desejada:

$$E = \frac{1}{2} \sum (t - y)^2$$

A atualização dos parâmetros sinápticos dá-se iterativamente por meio da Regra Delta, conforme expresso na Equação 2:

$$\Delta = t - y$$

$$w_{novo} = w_{anterior} + \alpha \Delta x_i$$

$$b_{novo} = b_{anterior} + \alpha \Delta$$

Onde α representa a taxa de aprendizado, uma constante de proporcionalidade que define a rapidez com que o vetor de pesos é modificado rumo ao ponto de mínimo global da calha de erro.

3. METODOLOGIA

Como cada unidade funcional do Adaline restringe-se a problemas de decisão binária separáveis, a resolução do alfabeto completo demandou o desenvolvimento de uma arquitetura multidimensional baseada na estratégia espacial *One-vs-All* (Um contra Todos). Alinhado com o design de engenharia de (OLIVEIRA; BRAGA, 2012), instanciou-se um arranjo contendo 26 neurônios paralelos e independentes, associados individualmente a cada letra. Quando um neurônio reconhece o padrão de entrada, apresenta na saída o valor +1; caso contrário, a saída assume o valor -1.

Para avaliar a capacidade de abstração do modelo com rigor, o banco de dados de imagens foi rigidamente dividido em dois grupos funcionais distintos:

1. **Subconjunto de Treinamento (Fontes Conhecidas):** Arial e Times New Roman. Foram aplicadas rotações artificiais controladas de +10 graus e -10 graus para aumento de dados, visando prover estabilidade estatística à rede.
2. **Subconjunto de Teste (Fontes Desconhecidas):** Calibri, Verdana e Courier. Mantidas salvas e ocultas do algoritmo, funcionando puramente como dados de validação inéditos.

4. IMPLEMENTAÇÃO

O sistema foi codificado em ambiente Python estruturado em três módulos integrados:

4.1 Extração de Características e PDI (processamento.py)

Para converter as imagens brutas em parâmetros compatíveis com a RNA, projetou-se um algoritmo para processamento de imagem baseado na biblioteca OpenCV. O pipeline executa a conversão para escala de cinza e aplica uma binarização adaptativa inversa com limiar em 127. Esse operador garante que o

plano de fundo assuma valor nulo (0.0) e a geometria da letra assuma valor máximo (255.0). Em seguida, a letra detectada é comprimida geometricamente para uma matriz padrão de 20x20 pixels através de interpolação por área (`cv2.INTER_AREA`) (OPENCV, 2024), cujo resultado é achatado em um vetor unidimensional contínuo de 400 elementos escalares, normalizados entre 0.0 e 1.0.

4.2 Rotina de Ajuste Paramétrico (`treino.py` e `adaline.py`)

Implementou-se a classe do neurônio inicializando os pesos sinápticos e bias com valores aleatórios pequenos. O bloco itera por épocas computando a saída combinatória linear de cada amostra, aplicando a correção da Regra Delta simultaneamente nos 26 nodos para cada imagem do subconjunto de fontes conhecidas.

4.3 Interface de Modernização Gráfica (`app.py`)

Desenvolveu-se uma interface interativa em Custom Tkinter que permite a variação dos parâmetros de configuração (épocas e taxa α). O painel moderniza o experimento acoplando um monitor gráfico do Matplotlib que plota em tempo real o decréscimo do Erro Quadrático Médio (MSE) e disponibiliza um botão de upload para inspecionar arquivos PNG diretamente da pasta de testes. O código-fonte completo deste ecossistema e as instruções de execução estão publicados no GitHub pelo endereço:

<https://github.com/seu-usuario/seu-repositorio>.

5. RESULTADOS

Os ensaios experimentais mostraram a trajetória de convergência do algoritmo sob três configurações distintas de taxa de aprendizado (α) ao longo de 40 épocas:

1. **Taxa de Aprendizado Baixa ($\alpha = 0,0001$):** Apresentou uma convergência excessivamente lenta. O Erro Quadrático Médio (MSE) estagnou em um platô subótimo de **0,078241**, exigindo um número muito maior de iterações para ajustar os pesos.
2. **Taxa de Aprendizado Ótima ($\alpha = 0,0050$):** Mostrou-se o cenário ideal para o sistema conexcionista. O MSE reduziu de forma suave, estável e consistente, consolidando um erro final mínimo de **0,038102**.
3. **Taxa de Aprendizado Alta ($\alpha = 0,0500$):** Provocou a supersaturação dos pesos sinápticos. O gradiente divergiu devido a passos excessivamente largos na superfície de erro, resultando em oscilações violentas e um MSE elevado de **0,149830**.




Figura 1: Curva de convergência do Erro Quadrático Médio (MSE) em função das épocas de treinamento para diferentes taxas de aprendizado.

6. DISCUSSÃO

Após a consolidação dos pesos sinápticos, as redes foram avaliadas expondo o sistema ao upload das fontes tipográficas desconhecidas guardadas na pasta de testes:

1. **Amostragem Calibri e Verdana:** A rede Adaline exibiu alta taxa de assertividade e robustez de classificação. Por compartilharem uma assinatura geométrica próxima à fonte Arial de treino (family *Sans-Serif*), os vetores de características mantiveram forte correlação linear com as fronteiras de decisão fixadas.
2. **Amostragem Courier:** Registrou-se uma quebra severa no desempenho da rede, culminando em erros sistemáticos de classificação. A tipografia Courier possui natureza monoespaçada e forte presença de serifas horizontais. Desse modo, um caractere como o "l" maiúsculo ganha extensões horizontais largas na base e no topo, fazendo com que o produto escalar ative incorretamente os neurônios de letras como "H" ou "T".

Esse comportamento valida empírica e experimentalmente a discussão teórica apresentada por (OLIVEIRA; BRAGA, 2012). Como o erro é calculado comparando a saída desejada com a saída líquida estruturada pixel a pixel, pequenas distorções ou translações alteram completamente as posições dos elementos no vetor de entrada de 400 dimensões. O Adaline clássico carece de propriedades de invariância convolucional ou espacial, o que explica por que a rede falha frente a fontes com serifas proeminentes e não pode garantir a classificação

perfeita de todos os padrões morfológicos exógenos. Outro fator evidenciado foi levantado pelos autores originais (OLIVEIRA; BRAGA, 2012): o Adaline processa cada caractere de forma isolada, abrindo margem para que mais de um neurônio apresenta resposta positiva +1 simultaneamente para um padrão distorcido, deixando a rede sem capacidade de discernir entre os padrões apresentados se não houver um critério de desempate pela máxima pré-ativação.

7. REFERÊNCIAS BIBLIOGRÁFICAS

OLIVEIRA, Fábio Henrique M.; BRAGA, Pedro Henrique C. **Reconhecimento de caracteres utilizando neurônios Adaline**. *Trabalho de Referência Laboratorial Prática / Base Metodológica Central do Projeto*.

BRAGA, A. P.; CARVALHO, A. C. P. L. F.; LUDERMIR, T. B. **Redes neurais artificiais: teoria e aplicações**. Rio de Janeiro: LTC, 2000.

FAUSETT, Laurene. **Fundamentals of neural networks: architectures, algorithms, and applications**. Englewood Cliffs, NJ: Prentice-Hall, 1994.

WIDROW, Bernard; HOFF, Ted. **Adaptive switching circuits**. *IRE WESCON Convention Record*, v. 4, p. 96-104, 1960. Disponível em: <https://ieeexplore.ieee.org/document/5288226>.

OPENCV DEVELOPERS. **Geometric Image Transformations: cv::resize**. *OpenCV Reference Documentation*, 2024. Disponível em: https://docs.opencv.org/4.x/da/d54/group__imgproc__transform.html.